



Presented by. 4명이었던..팀

머물고 싶은 사람은 티가 난다

머신러닝 모델과 K-means 군집 분석으로 도출한
결제 전환 신호와 타겟 마케팅 제안

2025.11.27 - 2025.12.08 | 전수복 | 류동균 | 조정민






Contents

- 1 분석 배경 & 문제 정의
- 2 핵심 전략 & 기대효과
- 3 데이터 개요 & 전처리
- 4 주요 발견
- 5 예측 모델 & 클러스터링
- 6 한계점 및 제언





Contents

1 분석 배경 & 문제 정의



1 | 분석 배경 & 문제 정의

공유오피스의 경쟁력은 ‘고객의 경험’에 있다.

1

팬데믹 이후
유연한 업무 공간
수요 증가

2

접근성
업무·공부 효율을 높이는 공간
첫 방문 시 경험의 만족도(UX)

3

‘누가 실제 결제 고객으로
이어지는가?’
→ 행동 기반 분석 필요성 대두

1 | 분석 배경 & 문제 정의

무료체험 고객 9,631명 중 62.1%가 결제로 이어지지 않는다.

1


약 **1:1.6**의 클래스 불균형
3,664명(37.9%) : 5,995명(62.1%)

2

어떤 고객을 타겟으로
마케팅을 진행할까?

3

‘전환 가능성이 높은 잠재군’
→ 유료 고객으로
전환시킬 마케팅 전략 필요



Contents

1 분석 배경 & 문제 정의

2 핵심 전략 & 기대효과



마지막까지 완주하게 만들 3단계 마케팅 전략 제안

초기 이탈형(Cluster 0) 타겟	완주형(Cluster 1·3) 타겟	VIP형(Cluster 2) 타겟
‘첫날 몰입 패키지’	‘업셀링 중심 개인화 마케팅’	‘초고속 전환 패스’

2 | 핵심 전략 제안 & 기대효과

초기 이탈형(Cluster 0) 타겟 : ‘첫날 몰입 패키지’

초기 이탈형(Cluster 0) 타겟	완주형(Cluster 1·3) 타겟	VIP형(Cluster 2) 타겟
‘첫날 몰입 패키지’	‘업셀링 중심 개인화 마케팅’	‘초고속 전환 패스’

2 | 핵심 전략 제안 & 기대효과

초기 이탈형(Cluster 0) 타겟 : ‘첫날 몰입 패키지’

목표	실행	기대효과
첫 날 체험의 만족도 상승 → Day2·Day3 방문을 유도	스낵 콘텐츠, 실시간 고객 응대 ‘1-Day Nudge’ 메시지	첫날 체험 만족도 상승 → 전체 체험일수 증가 → 결제 전환율 향상

2 | 핵심 전략 제안 & 기대효과

완주형(Cluster 1·3) 타겟 : ‘업셀링 중심 개인화 마케팅’

초기 이탈형(Cluster 0) 타겟	완주형(Cluster 1·3) 타겟	VIP형(Cluster 2) 타겟
‘첫날 몰입 패키지’	‘업셀링 중심 개인화 마케팅’	‘초고속 전환 패스’

2 | 핵심 전략 제안 & 기대효과

완주형(Cluster 1·3) 타겟 : ‘업셀링 중심 개인화 마케팅’

목표	실행	기대효과
기존 체류 패턴을 유지 및 강화 → 장기 구독으로 연결	방문 요일·시간대별 개인화 마케팅 캠페인	긍정적인 경험 지속 → ‘무제한 회원권’ 결제 등 수익성 극대화

2 | 핵심 전략 제안 & 기대효과


VIP형(Cluster 2) 타겟 : ‘초고속 전환 패스’

초기 이탈형(Cluster 0) 타겟	완주형(Cluster 1·3) 타겟	VIP형(Cluster 2) 타겟
‘첫날 몰입 패키지’	‘업셀링 중심 개인화 마케팅’	‘초고속 전환 패스’

2 | 핵심 전략 제안 & 기대효과

VIP형(Cluster 2) 타겟 : ‘초고속 전환 패스’

목표	실행	기대효과
방문 목적이 명확한 고객군에게 빠른 결정을 내리도록 유도	단순화된 결제 흐름 제공	결제율이 가장 높은 ‘VIP 고객군’의 전환율 극대화



Contents

1 분석 배경 & 문제 정의

2 핵심 전략 & 기대효과

3 데이터 개요 & 전처리




3 | 데이터 개요 & 전처리

분석 데이터 개요와 주요 전처리

데이터 기간	사용데이터	데이터 사이즈	주요변수
2021.05.01 ~ 2023.12.31	site_area.csv (지점별 면적)	9행 × 2열	'site_id', 'area_pyeong'
	trial_access_log.csv (3일체험 신청자 출입기록)	63,708행 × 5열	'id', 'checkin', 'cdate', 'site_id', 'user_uuid'
	trial_payment.csv (3일체험 신청자 결제 여부)	9,659행 × 2열	'is_payment', 'user_uuid'
	trial_register.csv (3일체험 신청)	9,659행 × 2열	'trial_date', 'user_uuid'
	trial_visit_info.csv (3일체험 신청자 일자별 방문기록)	11,477행 × 7열	'site_id', 'date', 'stay_time', 'stay_time_second', 'first_enter_time', 'last_leave_time', 'user_uuid'

분석 데이터 개요와 주요 전처리

중복데이터 제거	결측치 처리	논리적 오류값 처리
‘trial_access_log’(359행) ‘trial_payment’(35행) ‘trial_register’(28행) ‘trial_visit_info’(48행) → 총 470건의 중복값 제거	‘trial_visit_info’ 테이블의 ‘first_enter_time’, ‘last_leave_time’ 컬럼 → 총 555행 제거	시간 데이터의 논리적 오류 처리, 최대 3일의 무료체험 기간이 4일로 집계되는 고객 존재



Contents

1 분석 배경 & 문제 정의

2 핵심 전략 & 기대효과

3 데이터 개요 & 전처리

4 주요 발견



4 | 주요 발견

고객의 행동 패턴, 핵심 발견 3가지

1

**3일 체험을 채우면
고객의 지갑도 열린다.**

2

첫인상이 결제를 좌우한다.

3

**방문 지연 그룹은
유료 고객이 될 가능성이 높은
중요한 잠재 고객이다.**

4 | 주요 발견

첫 번째 발견, 3일 체험을 채우면 고객의 지갑도 열린다.

1

**3일 체험을 채우면
고객의 지갑도 열린다.**

2

첫인상이 결제를 좌우한다.


3

방문 지연 그룹은
유료 고객이 될 가능성이 높은
중요한 잠재 고객이다.

4 | 주요 발견

첫 번째 발견, 3일 체험을 채우면 고객의 지갑도 열린다.

- ✓ 첫방문 → 재방문 → 3일 방문으로 갈수록 전환율이 높아짐
- ✓ 결제와 미결제 간 격차가 줄어듦



구분	결제	미결제
첫방문	32.90%	67.10%
재방문	41.30%	58.70%
3일 방문	48.20%	51.80%

4 | 주요 발견

두 번째 발견, 첫인상이 결제를 좌우한다.

1

3일 체험을 채우면
고객의 지갑도 열린다.

2

첫인상이 결제를 좌우한다.


3

방문 지연 그룹은
유료 고객이 될 가능성이 높은
중요한 잠재 고객이다.

4 | 주요 발견

두 번째 발견, 첫인상이 결제를 좌우한다.

- ✓ 첫 방문 집단에서 30분~1시간으로 짧은 시간 동안 체류 → 결제하는 고객의 수는 가장 많음
- ✓ 즉, 첫 방문 시의 첫 인상이 긍정적으로 남은 고객들이 높은 결제 전환을 보이기 때문에, 초반 1시간 이내에 서비스의 핵심 경험을 제공하는 것이 중요할 것으로 판단



4 | 주요 발견

세 번째 발견, 방문 지연 그룹은 유료 고객이 될 가능성이 높은 중요한 잠재 고객이다.

1

3일 체험을 채우면
고객의 지갑도 열린다.

2

첫인상이 결제를 좌우한다.



3


**방문 지연 그룹은
유료 고객이 될 가능성이 높은
중요한 잠재 고객이다.**

4 | 주요 발견

세 번째 발견, 방문 지연 그룹은 유료 고객이 될 가능성이 높은 중요한 잠재 고객이다.

- ✓ 등록 후 방문이 다소 지연된 그룹(체험 등록 후 3일째에 방문)은 **결제율(44.2%)**이 가장 높음
- ✓ 결제율은 높지만 체류시간은 낮음 : **결제 이후에도 실제 사용은 적을 가능성** → 높은 LTV 기대





Contents

1 분석 배경 & 문제 정의

2 핵심 전략 & 기대효과

3 데이터 개요 & 전처리

4 주요 발견

5 예측 모델 & 클러스터링



5 | 예측 모델 & 클러스터링

고객의 행동을 예측하고 고객 군집 정의하기

1

피처 엔지니어링

2

예측 모델

3

클러스터링

5 | 예측 모델 & 클러스터링

고객의 행동을 예측하고 고객 군집 정의하기

1

피처 엔지니어링

2

예측 모델

3

클러스터링

5 | 예측 모델 & 클러스터링

피처 엔지니어링

✓ 예측 모델에 사용할 피처 생성 (주요 변수만 일부 발췌)

컬럼명	Type	설명	상세 내용
day1_stay_time	INTEGER	첫째 날 재실시간(초)	stay_time_second 기반
day2_stay_time	INTEGER	둘째 날 재실시간(초)	stay_time_second 기반
day3_stay_time	INTEGER	셋째 날 재실시간(초)	stay_time_second 기반
drop_12	FLOAT	Day1 → Day2 감소율	$(\text{day1} - \text{day2}) / (\text{day1} + 1)$
drop_23	FLOAT	Day2 → Day3 감소율	$(\text{day2} - \text{day3}) / (\text{day2} + 1)$
visit_days	INTEGER	3일 동안 방문한 날짜 수	(0, 1, 2, 3)
days_to_visit	INTEGER	신청일부터 첫 방문까지 걸린 일수	initial_visit_date - trial_date

5 | 예측 모델 & 클러스터링

최종 모델, RandomForest + SMOTE

1

피처 엔지니어링

2

예측 모델

3

클러스터링

최종 모델, RandomForest + SMOTE

- ✓ RandomForest(SMOTE 적용) 모델 성능 : **AUC(0.6407), Accuracy(0.645), Recall(0.41)**
- ✓ 동일 조건에서 XGBoost 대비 예측 성능이 안정적이라고 판단하여 최종 모델로 선정


모델	AUC	Accuracy	Precision (0)	Precision (1)	Recall (0)	Recall (1)	F1-score (0)	F1-score (1)
RandomForest + SMOTE	0.6407	0.6454	0.68	0.55	0.79	0.41	0.73	0.47
XGBoost + SMOTE	0.6313	0.6361	0.67	0.54	0.8	0.38	0.73	0.45

5 | 예측 모델 & 클러스터링

최종 모델, 피처 중요도 분석

✓ RandomForest(SMOTE 기법 사용) 피처 중요도 분석 결과

순위	상세내용
1	‘day1_stay_time’(첫째 날 재실시간, 초단위)
2	‘drop_12’(Day1 → Day2 감소율)
3	‘initial_cos_hour’(최초 방문 시각 cos 변환)
4	‘initial_cos_month’(최초 방문 월 cos 변환)
5	‘initial_sin_week’(요일 sin 변환)
6	‘day2_stay_time’(둘째 날 재실시간, 초단위)
7	‘initial_sin_hour’(최초 방문 시각 sin 변환)
8	‘initial_sin_month’(최초 방문 월 sin 변환)
9	‘trial_sin_week’(요일 sin 변환)
10	‘day1_site_id’(첫째 날 방문한 지점)



5 | 예측 모델 & 클러스터링

클러스터링 결과 및 프로파일링

1

피처 엔지니어링

2

예측 모델



3

클러스터링

5 | 예측 모델 & 클러스터링

클러스터링 결과 및 프로파일링

- ✓ 최적의 군집 수(k)를 선택하기 위해 Elbow Method와 Silhouette Score 지표를 함께 사용
- ✓ 최종 군집 수 : 4 (Elbow Method의 안정성 + Silhouette Score의 품질 평가 + 비즈니스 해석력을 종합)



5 | 예측 모델 & 클러스터링

클러스터링 결과 및 프로파일링

✓ 각 군집별 핵심 행동 요약


구분 \ Cluster	Cluster 0	Cluster 1	Cluster 2	Cluster 3
고객 수	2,374	1,329	1,875	2,500
Day1 체류시간	14,323	23,078	10,377	14,395
Day2 체류시간	4,913	29,703	6,745	4,995
Day3 체류시간	120	17,534	1,893	177
Days_to_visit (신청일부터 첫 방문까지 걸린 일수)	1.19	0.73	2.17	1.18
Drop_12 (Day1 → Day2 감소율)	0.38	-3.69	-0.69	0.32
Drop_23 (Day2 → Day3 감소율)	0.3	-1.41	0.49	0.29
Payment_rate (결제 전환율)	34.46%	42.96% (최고)	50.00% (결제율 1위, 극소수군)	40.32%
visit_days (방문 일수)	1.41	2.87	1.75	1.41

5 | 예측 모델 & 클러스터링

클러스터링 결과 및 프로파일링

- ✓ 크게 두 가지 주요 행동 유형으로 구분
- ✓ 이탈형 고객군(Cluster 0)
- ✓ 완주형·고관여 고객군(Cluster 1, 3, VIP Cluster 2)

고객 구분	세부 내용
이탈형 고객군 (Cluster 0)	Cluster 0 — 초기 관심 후 이탈형 (~2,374명, 전체의 약 30%)
완주형 / 고관여 고객군 (Cluster 1, 3 / VIP Cluster 2)	Cluster 1 — 고관여 완주형 (전체의 약 23%) Cluster 2 — 극소수 VIP형 (전체의 1~2%) Cluster 3 — 자연 소극형 (전체 약 33%)



Contents

1 분석 배경 & 문제 정의

2 핵심 전략 & 기대효과

3 데이터 개요 & 전처리

4 주요 발견

5 예측 모델 & 클러스터링

6 한계점 및 제언



데이터의 한계, 그리고 향후 과제

한계점
출입 로그 일부 누락(결측치) stay_time 기반의 제한적인 행동 해석 3일 체험 구조로 행동 다양성 제약 결제 여부 외 LTV 정보 부족

향후 과제
시퀀스 분석(Markov)으로 방문 흐름 분석 지점 특성 반영한 공간 최적화 모델 캠페인 A/B test로 실제 효과 검증 LTV 예측 모델 확장

Thank you!

QnA

Presented by. 4명이었던..팀