

머물고 싶은 사람은 티가 난다

머신러닝 모델과 K-means로 도출한 전환 신호와 타겟 마케팅 제안

2025.11.27 - 2025.12.08

CODEIT DA 9기 | 4명이었던..팀

(팀장) 전수복

류동균

조정민

목차 | CONTENTS

1. 분석 요약 Executive Summary	3
2. 분석 배경 및 문제 정의 Background & Problem Definition	4
2.1. 분석 배경: 경쟁력은 ‘고객의 경험’에 있다.	
2.2. 문제 정의: ‘무료체험’ 뒤에 숨은 고객의 속마음은 무엇일까?	
2.3. 분석 목표: 예측 모델과 클러스터링을 통한 잠재고객 발굴 및 수익성 극대화	
3. 분석 프레임워크 및 분석 방법 Analysis Framework & Methodology	5
3.1. 분석 환경 및 데이터 기본정보	
3.2. 데이터 품질 관리 및 전처리	
3.3. 변수 탐색 및 핵심 동인(Feature) 분석	
3.4. 예측 모델 및 클러스터링 비교 요약	
4. 주요 발견 Key Findings	9
4.1. 발견1: 3일 체험을 채우면 지갑도 열린다. *근거: 첫방문 → 재방문 → 3일 방문으로 갈수록 전환율이 높아지고, 결제와 미결제 간 격차가 줄어들	
4.2. 발견2: 첫인상이 결제를 좌우한다. *근거: 첫 방문 집단에서 30분~1시간으로 짧은 시간 동안 체류했지만 결제하는 고객수는 가장 많음	
4.3. 발견3: 퇴근 후에 오는 사람들의 마음은 진심이다. *근거: 3일 무료체험을 완주한 고객의 요일·시간대별 ‘결제자·비결제자’ 수가 퇴근 후(평일 18~21시)에 높게 나타남	
4.4. 발견4: 방문 지연 그룹은 유료 고객이 될 가능성이 높은 중요한 잠재 고객이다. *근거: 등록 후 방문이 다소 지연된 그룹(체험 등록 후 3일째에 방문)은 결제율(44.2%)이 가장 높게 나타남	
4.5. 발견5: 3일 완주 그룹은 ‘목적 지향형 고객’이다. *근거: 3일 완주 그룹은 ‘days_to_visit’(리드타임) 0인 구간에서 0.49라는 매우 높은 전환율을 기록	
5. 예측모델 결과 및 해석 Clustering Results & Interpretation	13
5.1. 피쳐 생성 및 엔지니어링	
5.2. 사용한 모델 및 최종 모델 선정 이유	
5.3. 피쳐 중요도 분석	
6. 클러스터링 결과 및 해석 Clustering Results & Interpretation	16
6.1. 사용한 클러스터링 모델 및 선정 이유	
6.2. 결과 및 각 군집별 프로파일링	
7. 전략 제안 및 기대효과 Strategic Recommendations & Expected Impact	19
7.1. 제안 요약: 마지막까지 완주하게 만들 3단계 마케팅 전략 제안	
7.2. 제안1: 초기 이탈형 고객(Cluster 0) 대상 ‘첫날 몰입 패키지’	
7.3. 제안2: 완주형 고객(Cluster 1·3) 대상 ‘업셀링 유도’	
7.4. 제안3: 빠른 판단형 고객(VIP)(Cluster 2) 대상 ‘초고속 전환 패스’	
8. 측정 계획 Measurement Plan	21
8.1. 초기 이탈형 고객(Cluster 0) 대상 ‘첫날 몰입 패키지’의 효과 측정계획	
8.2. 완주형 고객(Cluster 1·3) 대상 ‘업셀링 유도’ 전략의 효과 측정계획	
8.3. 빠른 판단형 고객(VIP)(Cluster 2) 대상 ‘초고속 전환 패스’의 효과 측정계획	
9. 부록 Appendix	23
9.1. 데이터 명세서	
9.2. 연·월·요일·시간대별 방문 고객 탐색	
9.3. 한계점 및 향후 과제	

1. 분석요약

- **Problem (핵심문제)** : 2021년 5월 ~ 2023년 12월까지 'J'사의 무료 체험 고객 중 유료 회원으로 전환된 고객은 3,664명(37.9%), 전환되지 않은 고객은 5,995명(62.1%)로 약 1:1.6의 불균형 문제가 나타났습니다. 이러한 상황은 'J'사가 잠재적인 고객을 놓치고 있는 가능성을 시사합니다.
- **Analysis (분석개요)** : 본 분석은 공유 오피스 'J'사의 무료 체험 데이터를 기반으로 고객의 방문 행동 패턴을 정밀하게 파악하고, 머신러닝 기반 예측 모델과 클러스터링을 통해 전환 가능성이 높은 고객군을 선별하고 그에 따른 마케팅 전략을 제안하는데 초점을 두었습니다.
- **Key Findings (주요발견 및 분석 결과)** : 공유오피스를 방문하는 고객의 입·퇴실 기록에 대한 데이터를 활용하여 다음과 같은 고객의 주요 패턴을 발견하였습니다. 첫째, 체험 방문 일수가 많을 수록 결제 전환이 이루어집니다. 둘째, 첫 방문 경험이 결제 여부를 좌우합니다. 셋째, 퇴근 시간대 방문 고객은 높은 목적성을 보입니다. 넷째, 등록 후 방문이 지연된 그룹은 오히려 결제율이 높게 나타납니다. 마지막으로, 3일 완주 그룹은 처음부터 강한 의도를 가진 고객군으로 확인되었습니다.
이를 바탕으로 모델링과 클러스터링 분석을 진행, AUC(ROC곡선 아래의 면적), Accuracy(정확도), Precision(정밀도), Recall(재현율), F1-score(Precision과 Recall의 조화평균)를 종합적으로 평가하고, 하이퍼 파라미터 튜닝을 통해 최적의 예측 모델을 구현하고자 하였습니다. 분석 결과, 'day1_stay_time' (첫째 날 재실시간, 초단위), 'drop_12'(Day1 → Day2 감소율), 'initial_cos_hour'(최초 방문 시각 cos 변환) 등의 순서로 중요한 변수를 확인할 수 있었습니다. 최종적으로는 AUC값(0.64)과 함께 실제 유료 전환을 한 고객을 실제로 모델이 잘 예측했는지 판단하기 위해 Recall값(0.41)을 기준으로 RandomForest + SMOTE 모델을 도입하여 예측에 활용하고자 하였습니다.
- **Recommendation (핵심제안)** : 첫째, 초기 이탈형 고객(Cluster 0) 대상 '첫날 물입 패키지'를 제안합니다. 둘째, 완주형 고객(Cluster 1·3) 대상 '업셀링 유도' 전략을 제안합니다. 셋째, 빠른 판단형 고객(VIP)(Cluster 2) 대상 '초고속 전환 패스' 전략을 제안합니다.

2. 분석 배경 및 문제 정의 | Background & Problem Definition

2.1. 분석 배경 : 경쟁력은 ‘고객의 경험’에 있다.

코로나19 이후 근무 환경이 급격하게 변화하면서 ‘유연한 업무 공간’, 집과 회사의 장점을 결합한 ‘거점(據點) 사무실’로서의 공유오피스에 대한 수요가 지속적으로 증가하고 있습니다.¹ 이제 공유오피스의 경쟁력은 단순한 공간 제공을 넘어, 접근성, 업무나 공부 효율을 높이는 공간 구성, 첫 방문 시 경험의 질(UX) 등 다양한 요인에 의해 결정됩니다. 이러한 흐름 속에서 ‘어떤 고객군이 실제 매출에 기여하는가?’, ‘체험만 하고 결제하지 않는 고객군은 얼마나 되는가?’, ‘첫 방문에서 결제까지의 여정(Funnel)을 어떻게 최적화할 것인가?’와 같은 정교한 고객 분석의 필요성이 더욱 커지고 있습니다.

즉, 고객을 여러 세그먼트로 나누고 각 그룹의 행동 패턴을 면밀히 파악하는 것은 필수 전략이라고 할 수 있습니다. 이러한 분석을 기반으로 고객의 행동을 예측하여 그에 맞는 마케팅 전략을 설계하고 실행한다면 고객유입(Acquisition) → 체험·전환(Activation) → 재방문(Retention) → 매출 창출(Revenue)로 이어지는 선순환 구조를 강화할 수 있습니다. 궁극적으로 이러한 데이터 기반 분석은 공유오피스의 전환율 개선, 고객 경험 향상, 수익성 극대화 등 비즈니스의 핵심 성과를 높이는 데 중요한 역할을 할 수 있습니다.

2.2. 문제 정의 : ‘무료체험’ 뒤에 숨은 고객의 속마음은 무엇일까?

2021년 5월 - 2023년 12월까지의 무료 체험 고객 중 유료 회원으로 전환된 고객은 3,664명(37.9%), 전환되지 않은 고객은 5,995명(62.1%)로 약 1.6:1의 불균형 문제가 나타났습니다. 따라서, 현재 놓치고 있을 수 있는 ‘유료 전환될 확률이 높은 잠재 고객’을 탐색하고 해당 그룹을 타겟으로 마케팅 전략을 실행할 필요가 있습니다.

‘J’사는 ‘3일 무료체험 후 결제’라는 경쟁력있는 온보딩 구조를 가지고 있기 때문에, ‘체험 이후 결제 전환 과정에서 어떤 고객이 전환하는가’에 대한 체계적인 분석이 중요한 비즈니스 목표 중 하나라고 볼 수 있습니다. 이때, 무료 체험을 경험한 고객이라도 모두 결제로 이어지는 것은 아니기 때문에 ‘첫 방문의 경험은 어땠는지’, ‘여러 방문을 통해 방문 패턴에 변화가 있는지’, ‘등록 후 실제 방문까지 걸리는 시간(리드타임)이 전환에 어떤 영향을 미치는지’ 등 고객 여정별 행동 특성에 따라 전환 가능성이 상당히 다르게 나타날 수 있습니다. 따라서, ‘전환 가능성이 높은 잠재군’을 식별하고, 해당 고객군을 유료 고객으로 전환시킬 마케팅 전략 모색이 필수적입니다.

2.3. 분석 목표 : 예측 모델과 클러스터링을 통한 잠재고객 발굴 및 수익성 극대화

본 분석은 단순히 고객들의 유입·방문을 분석하는 것에 그치는 것이 아닌, 다양한 머신러닝 모델을 구현하여 고객들의 결제로 이어지는 핵심 행동 패턴을 예측하고자 하였습니다. 또한, 클러스터링을 통해 각 고객 세그먼트를 정의하고 프로파일링을 진행하여, 그에 맞는 마케팅 전략을 제안함으로써 공유오피스의 수익성을 극대화하는 비즈니스 목표를 가지고 분석을 진행하였습니다.

¹ 김지섭. (2023.02.24). '거점 사무실'로 진화한 공유 오피스... 10조원 시장 다시 들쭉인다. <조선경제>. [URL](#)

박수호. (2023.10.03). 공유오피스 줄줄이 파산...한국 토종 기업은 살아남았다. <매일경제>. [URL](#)

3. 분석 프레임워크 및 분석 방법 | Analysis Framework & Methodology

3.1. 분석 환경 및 데이터 기본정보

분석에 활용한 데이터 개요와 분석 도구는 하기와 같습니다.

(1) 데이터 개요

데이터 기간	사용데이터	데이터 사이즈	주요변수
2021.05.01 ~ 2023.12.31	site_area.csv (지점별 면적)	9행 × 2열	'site_id', 'area_pyeong'
	trial_access_log.csv (3일체험 신청자 출입기록)	63,708행 × 5열	'id', 'checkin', 'cdate', 'site_id', 'user_uuid'
	trial_payment.csv (3일체험 신청자 결제 여부)	9,659행 × 2열	'is_payment', 'user_uuid'
	trial_register.csv (3일체험 신청)	9,659행 × 2열	'trial_date', 'user_uuid'
	trial_visit_info.csv (3일체험 신청자 일자별 방문기록)	11,477행 × 7열	'site_id', 'date', 'stay_time', 'stay_time_second', 'first_enter_time', 'last_leave_time', 'user_uuid'

[표 1] 데이터 개요

(2) 저장 및 불러오기 라이브러리 : Google Drive

(3) 모델 사용 라이브러리 : Scikit-learn

(4) 시각화 사용 라이브러리 : Matplotlib, Seaborn, Plotly

(5) 모델링 : 데이터 누수 방지를 위해 모든 통계값은 train 데이터 기준으로만 계산 후 test 데이터에 적용

3.2. 데이터 품질 관리 및 전처리

분석 결과의 신뢰도와 재현성을 확보하기 위해 하기와 같은 원칙에 따라 전처리 과정을 수행하였습니다.

(1) 중복데이터 제거

*대상 : 'trial_access_log'(359행), 'trial_payment'(35행), 'trial_register'(28행),
'trial_visit_info'(48행)으로 총 470건의 중복값

*처리 : 분석의 효율과 재현성 확보를 위해 중복값 제거

(2) 결측치 처리

*대상 : 'trial_visit_info' 테이블의 'first_enter_time', 'last_leave_time' 컬럼 (555행)

*처리 : 'trial_access_log'로 복원을 시도하였으나, 로그 기록 자체의 누락 가능성이 높다고 판단 후 제거

(3) 논리적 오류값 처리 :

*대상 : 'stay_time'(재실시간)은 결측치가 없고 'first_enter_time'(해당일자 첫 입실시간) 혹은
'last_leave_time'(해당일자 마지막 퇴실 시간)이 결측치인 고객, 'stay_time'이
'first_enter_time', 'last_leave_time'과 안 맞는 고객, 무료 체험은 최대 3일인데 4일로

집계되는 고객 존재

*처리 : 'first_enter_time', 'last_leave_time'의 결측치는 앞 사람을 따라 입·퇴실 하는 경우가 존재하여 집계 시 누락이 있을 수 있기 때문에 결측치 제거 후 순수 재실 시간인 'stay_time' 기준으로 분석, 4일 방문자는 3일 전부 방문 고객으로 판단하여 3일 집단으로 분류

(4) 날짜 변환 : 시간 변수 datetime으로 통일(pd.to_datetime)하여 시계열 분석의 일관성을 확보

(5) 파생 변수 생성 : 변수 간 상관관계 및 EDA를 위해 'visit_days', 'delay_bin', 'weekday', 'hour', 'stay_min' 등의 파생변수를 생성


파생변수명	상세내용
'visit_days'	user별 방문 일수(고유 날짜 수)
'delay_bin'	등록일부터 예약일까지의 리드타임 구간화
'year'	연도(2021~2023)
'weekday'	요일(월~일)
'hour'	시간(24시간)
'stay_min'	'stay_time_seconds'를 분 단위로 변환

[표 2] 파생 변수 생성

3.3. 변수 탐색 및 핵심 동인(Feature) 분석

본 분석은 공유오피스에 방문하는 고객들의 방문 패턴을 분석하고 그에 맞는 마케팅 전략을 제안함으로써 공유오피스의 수익성을 극대화하기 위해 하기와 같은 분석을 진행하였습니다.


첫째, 데이터 불균형에 대해 탐색하였습니다. 예측하고자 하는 타겟변수 'is_payment'(결제 여부 : 결제=1, 미결제=0)에 대해 파악한 결과, 2021년 5월 - 2023년 12월까지의 무료 체험 고객 중 유료 회원으로 전환된 고객은 3,664명(37.9%), 전환되지 않은 고객은 5,995명(62.1%)로 약 1.6:1의 불균형 문제가 나타났습니다. 따라서, 추후 모델링 진행 시 클래스 불균형을 해소하기 위해 SMOTE 기법을 활용하고, Accuracy(정확도) 등 다양한 평가 지표를 함께 판단함으로써 모델의 판별 능력을 극대화하고자 하였습니다.



[그래프 1] 무료 → 유료 전환 수 (좌) / [그래프 2] 무료 → 유료 전환 비율 (우)


둘째, 무료 체험의 방문 일수별(0~3일) 그룹을 나누어 비교, 분석하였습니다. 먼저 방문 일수별 유료 전환율,

체류시간 분포를 탐색하고, 이후 각 세그먼트별 세부 분석을 진행하였습니다. 이때, 4일로 집계된 고객들이 있었으나 다음날로 넘어가는 시점까지 머무르거나 로그 누락 등 공통적인 특이점을 발견하지 못하여 해당 그룹은 3일 방문 고객이라고 판단, 해당 그룹에 함께 포함시켜 분석하였습니다.



[그래프 3] 방문 일수별 유료 전환수와 전환율 (좌) / [그래프 4] 방문 일수별 체류 시간 분포 (우)

마지막으로, 지도학습 머신러닝을 통해 지원율에 영향을 주는 변수의 순위를 확인하여, 분석의 우선 순위를 결정하였습니다. 선정된 핵심 변수는 1위 'days_to_visit' (예약일 → 첫 방문까지 걸린 일수), 2위 'day1_stay_time_log' (첫째 날 재실시간/log scaled 적용), 3위 'day1_site_id' (첫째 날 방문한 지점), 4위 'initial_mont' (최초 방문 월(1~12)), 5위 'visit_days' (3일 동안 방문한 날짜 수) 등의 순으로 나타났습니다. 이를 통해, 'days_to_visit', 'visit_days' 변수가 전체 흐름을 설명할 수 있는 구조적인 변수이며, 다른 변수들과 함께 보면 더 중요한 의미를 가질 것으로 판단하여, 추후 분석에서는 예약일부터 첫 방문까지 걸린 일수를 탐색하고, 방문 일수별 '첫방문', '재방문', '3일 방문'으로 고객 세그먼트를 나누어 분석을 진행하였습니다.



[그래프 5] 방문 일수별 유료 전환수와 전환율

3.4. 예측 모델 및 클러스터링 비교 요약

예측에 사용된 모델은 SMOTE기법을 활용한 RandonForest와 XGBoost입니다. 모델을 평가하기 위한 평가지표로는 AUC(ROC곡선 아래의 면적), Accuracy(정확도), Precision(정밀도), Recall(재현율), F1-score(Precision과 Recall의 조화평균)를 사용하였습니다. 또한, 클래스 간 중요도를 동일하게 고려하는 macro 지표와 각 클래스 간 샘플 수의 불균형을 고려하여 가중치를 주는 Weighted 지표를 함께 비교하였습니다.

해당 지표들을 선택한 이유는 클래스 불균형 문제를 다룸에 있어 특정 지표 한 가지만으로 판단하기에는

비즈니스 상황과 마케팅 캠페인 목표 등에 따라 모델 성능을 평가할 수 있는 기준이 달라지기 때문입니다. 금번 분석에서는 실제 결제 고객(1)을 놓치지 않고 탐지하는 것이 핵심 목표이므로 AUC와 Recall을 중심으로 모델의 성능을 평가하는 것이 적절하다고 판단하였습니다.

모델 평가 결과, 두 모델 모두 결제 고객(1)에 대한 Recall이 0.38~0.41 수준으로 나타났으며, 이는 불균형 데이터 상황에서 결제 고객의 예측 난이도가 미결제 고객에 비해 상대적으로 높다는 점을 보여줍니다. 그럼에도 불구하고 SMOTE와 적절한 평가 지표를 통해 모델 전반의 성능을 균형 있게 검토할 수 있었습니다.

- 구현 모델 : RandomForest + SMOTE, XGBoost + SMOTE
- 평가지표 : AUC, Accuracy, Precision, Recall, F1-score, Macro Precision, Macro Recall, Macro F1, Weighted Precision, Weighted Recall, Weighted F1
- 모델별 전체 성능 요약

모델	AUC	Accuracy	Precision (0)	Precision (1)	Recall (0)	Recall (1)	F1-score (0)	F1-score (1)
RandomForest + SMOTE	0.6407	0.6454	0.68	0.55	0.79	0.41	0.73	0.47
XGBoost + SMOTE	0.6313	0.6361	0.67	0.54	0.80	0.38	0.73	0.45

[표 3] 모델별 전체 성능 요약 (AUC, Accuracy, Precision, Recall, F1-score)

- Macro / Weighted Score 비교

모델	Macro Precision	Macro Recall	Macro F1	Weighted Precision	Weighted Recall	Weighted F1
RandomForest + SMOTE	0.62	0.60	0.60	0.63	0.64	0.63
XGBoost + SMOTE	0.61	0.59	0.59	0.62	0.64	0.62

[표 4] 모델별 Macro / Weighted Score 비교

K-means 군집분석 기법을 활용하여 고객 세그먼트를 정의하고 행동 패턴을 분석하였습니다. 그 결과, 고객은 크게 하기와 같은 두 가지 주요 행동 유형으로 구분할 수 있었습니다.


고객 구분	세부 내용
이탈형 고객군 (Cluster 0)	Cluster 0 — 초기 관심 후 이탈형 (~2,374명, 전체의 약 30%)
완주형 / 고관여 고객군 (Cluster 1, 3, VIP Cluster 2)	Cluster 1 — 고관여 완주형 (전체의 약 23%) Cluster 2 — 극소수 VIP형 (전체의 1~2%) Cluster 3 — 자연 소극형 (전체 약 33%)

[표 5] 클러스터링 결과 요약

4. 주요 발견 | Key Findings

4.1. 발견1 : 3일 체험을 채우면 지갑도 열린다.

***근거:** 첫방문 → 재방문 → 3일 방문으로 갈수록 전환율이 높아지고, 결제와 미결제 간 격차가 줄어드는 점을 확인하였습니다. 이는 재방문 자체가 결제 전환의 강력한 지표라고 볼 수 있습니다. 1일차는 결제와 미결제 비율이 각각 32.9%, 67.1%로 격차가 매우 크지만, 2일차에는 41.3%와 58.7%, 3일차는 48.2%, 51.8%로 거의 비슷해집니다. 이는 한 번 와보고 끝나는 것이 아니라, ‘충분히 경험하면 결제한다’는 확실한 행동 패턴이라고 할 수 있습니다. 따라서, 무료 체험 고객들이 3일 모두 방문하고 그 기간 동안의 긍정적인 경험을 통해 결제 전환까지 이어질 수 있도록 하는 전략이 필요할 것입니다.




구분	결제	미결제
첫방문	32.9%	67.1%
재방문	41.3%	58.7%
3일 방문	48.2%	51.8%

[그래프 6] 방문 일자별 결제/미결제 전환율 / [표 6] 방문 일자별 결제/미결제 전환율


4.2. 발견2 : 첫인상이 결제를 좌우한다.

***근거:** 첫 방문 집단에서 30분~1시간으로 짧은 시간 동안 체류했지만 결제하는 고객의수는 가장 많았습니다. 이처럼 첫 방문 시의 첫 인상이 긍정적으로 남은 고객들이 높은 결제 전환을 보이기 때문에, 초반 1시간 이내에 서비스의 핵심 경험을 제공하는 것이 중요할 것으로 판단됩니다.


한편, 재방문 집단에서는 3시간~3시간 30분, 3일 전부 방문한 집단에서는 5시간~5시간 30분으로 방문 일수가 늘어날수록 체류 시간도 길어지고 결제 전환도 많이 되는 패턴을 보입니다. 이는 공유오피스 내에서 시간을 오래 쓴 고객은 결제 잠재력이 있는 고객군으로 볼 수 있습니다.



[그래프 7] 첫 방문 고객 체류시간 분포




[그래프 8] 재방문 고객 체류시간 분포




[그래프 9] 3일 방문 고객 체류시간 분포

4.3. 발견4 : 퇴근 후에 오는 사람들의 마음은 진심이다.


***근거:** 요일·시간대별로 ‘결제자-비결제자’ 수의 분포를 살펴보면, 3일 무료체험을 끝까지 사용하는 고객은 퇴근 후(평일 18~21시) 서비스를 이용하는 수가 높으며, 이들을 실제 결제 전환의 핵심 그룹으로 볼 수 있습니다. 이는 첫 방문에서 업무시간 이후 잠시 들러서 공간을 이용하고, 긍정적인 경험을 통해 정기적으로 찾아오고 싶은 니즈가 명확히 생긴 ‘공간 사용에 진심인 고객’이라고 볼 수 있습니다. 즉, 이처럼 일상 루틴 속에 오피스 공간을 녹여내고 싶은 고객들의 니즈가 있음을 확인할 수 있었습니다.



[그래프 10] 첫 방문 고객 (결제자-비결제자) 수 요일별 시간대별 분포



[그래프 11] 재 방문 고객 (결제자-비결제자) 수 요일별 시간대별 분포




[그래프 12] 3일 방문 고객 (결제자-비결제자) 수 요일별 시간대별 분포

4.4. 발견4: 방문 지연 그룹은 유료 고객이 될 가능성이 높은 중요한 잠재 고객이다.

***근거:** 등록 후 방문이 다소 지연된 그룹(체험 등록 후 3일째에 방문)은 결제율(44.2%)이 가장 높은 점을 확인하였습니다. 또한, 결제율은 높지만 체류시간은 낮아 결제 이후에도 실제 사용은 적을 가능성을 염두에 둔다면, 높은 LTV가 기대되므로 수익화 관점에서 반드시 사로잡아야 하는 고객 그룹이라고 판단됩니다.

이때, 리드타임(체험 등록 후 실제 방문까지 걸리는 시간)이 길수록 오히려 증가하는 경향을 보였고 특히 매우 지연(30일+)된 그룹은 결제율이 60%로 매우 높게 나타났지만, 매우 소수(10명)라서 이상치로 판단, 유의미한 집단으로 구분하지 않았습니다.




[그래프 13] 리드타임별 사용자 수와 결제율 분포(좌) / [그래프 14] 리드타임별 체류시간 분포 (첫 방문 기준)(우)

4.5. 발견5 : 3일 완주 그룹은 ‘목적 지향형 고객’이다.

***근거:** 리드타임(체험 등록 후 실제 방문까지 걸리는 시간, days_to_visit)과 방문 일수(visit_days) 변수를 함께 분석한 결과, 1일 체험 < 2일 체험 < 3일 체험 순으로 결제 전환율이 높고, 특히 3일차 체험자는 빠르게 방문(등록 후 0~1일 내)하고 결제까지 이어지는 패턴을 보였습니다.

이때, 리드타임(days_to_visit)과 방문일수(visit_days)는 서로 상관관계를 가지지만, 전환율을 결정짓는 핵심은 ‘체험일수 완주’임을 다시 한 번 확인했습니다. 1일 < 2일 < 3일 체험 순으로 전환율이 상승하며, 특히 3일 완주 그룹은 리드타임 0인 구간에서 0.49라는 매우 높은 전환율을 기록하였습니다. 즉, 전환을 결정짓는 핵심 요인은 ‘몇 일이나 체험을 채웠는가(완주 여부)’이며, 3일 완주자는 처음부터 결제를 염두에 두고 체험을 시작한 목적 지향형 고객으로 해석할 수 있다.



[그래프 15] 리드타임, 방문 일수별 결제 전환수(좌) / [그래프 16] 리드타임, 방문 일수별 결제 전환율(우)

5. 예측 모델 결과 및 해석 | Clustering Results & Interpretation

5.1. 피처 생성 및 엔지니어링

앞선 주요 발견(4장) 내용을 바탕으로, 예측 모델에 사용할 피처를 하기와 같이 시간 기반 변수, 방문 행동 변수, 순서·패턴 변수(drop), 요일·시간대 주기성 변수(sin/cos 변환), 지점 방문 정보, 첫 방문 리드타임(days_to_visit) 등으로 생성하였습니다.

컬럼명	Type	설명	상세 내용
trial_sin_week	INTEGER	3일체험 신청 요일 sin	
trial_cos_week	INTEGER	3일체험 신청 요일 cos	
day1_stay_time	INTEGER	첫째 날 재실시간(초)	stay_time_second 기반
day2_stay_time	INTEGER	둘째 날 재실시간(초)	stay_time_second 기반
day3_stay_time	INTEGER	셋째 날 재실시간(초)	stay_time_second 기반
drop_12	FLOAT	Day1 → Day2 감소율	$(\text{day1} - \text{day2}) / (\text{day1} + 1)$
drop_23	FLOAT	Day2 → Day3 감소율	$(\text{day2} - \text{day3}) / (\text{day2} + 1)$
visit_days	INTEGER	3일 동안 방문한 날짜 수	(0, 1, 2, 3)
days_to_visit	INTEGER	신청일부터 첫 방문까지 걸린 일수	initial_visit_date - trial_date
initial_visit_date	DATE	최초 방문 날짜(KST)	
initial_day_of_week	INTEGER	최초 방문 요일	0=월 ... 6=일
initial_sin_week	FLOAT	요일 sin 변환	$\sin(2\pi \times \text{요일}/7)$
initial_cos_week	FLOAT	요일 cos 변환	$\cos(2\pi \times \text{요일}/7)$
initial_hour	INTEGER	최초 방문 시각(0~23)	
initial_sin_hour	FLOAT	최초 방문 시각 sin 변환	$\sin(2\pi \times \text{hour}/24)$
initial_cos_hour	FLOAT	최초 방문 시각 cos 변환	$\cos(2\pi \times \text{hour}/24)$
initial_month	INTEGER	최초 방문 월(1~12)	
initial_sin_month	FLOAT	최초 방문 월 sin 변환	$\sin(2\pi \times \text{month}/12)$
initial_cos_month	FLOAT	최초 방문 월 cos 변환	$\cos(2\pi \times \text{month}/12)$
day2_hour	INTEGER	둘째 날 첫 방문 시각	

day2_sin_hour	FLOAT	둘째 날 첫 방문 시각 sin	$\sin(2\pi \times \text{hour}/24)$
day2_cos_hour	FLOAT	둘째 날 첫 방문 시각 cos	$\cos(2\pi \times \text{hour}/24)$
day3_hour	INTEGER	셋째 날 첫 방문 시각	
day3_sin_hour	FLOAT	셋째 날 첫 방문 시각 sin	$\sin(2\pi \times \text{hour}/24)$
day3_cos_hour	FLOAT	셋째 날 첫 방문 시각 cos	$\cos(2\pi \times \text{hour}/24)$
day1_site_id	INTEGER	첫째 날 방문한 지점	df_trial_visit_info['site_id']
day2_site_id	INTEGER	둘째 날 방문한 지점	df_trial_visit_info['site_id']
day3_site_id	INTEGER	셋째 날 방문한 지점	df_trial_visit_info['site_id']

[표 7] 추가 생성한 피쳐 개요

5.2. 사용한 모델 및 최종 모델 선정 이유

고객의 유료 결제 전환을 예측하기 위해 단일 모델과 앙상블 모델 총 2가지(RandomForest, XGBoost)를 구현하여 비교하였습니다. 이때, 평가 지표는 AUC(ROC곡선 아래의 면적), Accuracy(정확도), Precision(정밀도), Recall(재현율), F1-score(Precision과 Recall의 조화평균)를 사용하였습니다. 또한, 클래스 간 중요도를 동일하게 고려하는 macro 지표와 각 클래스 간 샘플 수의 불균형을 고려하여 가중치를 주는 Weighted 지표를 함께 비교하였습니다. 이는 클래스 불균형 문제를 다룸에 있어 특정 지표 한 가지만으로 판단하기에는 비즈니스 상황과 마케팅 캠페인 목표 등에 따라 모델 성능을 평가할 수 있는 기준이 달라지기 때문입니다.

이러한 평가 지표로 모델을 평가한 결과, RandomForest(SMOTE 적용) 모델이 AUC(0.6407), Accuracy(0.645), Recall(0.41)로 동일 조건에서 XGBoost 대비 예측 성능이 안정적이라고 판단하여 최종 모델로 선정하여 예측에 활용하고자 하였습니다.


모델	AUC	Accuracy	Precision (0)	Precision (1)	Recall (0)	Recall (1)	F1-score (0)	F1-score (1)
RandomForest + SMOTE	0.6407	0.6454	0.68	0.55	0.79	0.41	0.73	0.47
XGBoost + SMOTE	0.6313	0.6361	0.67	0.54	0.80	0.38	0.73	0.45

[표 8] 모델별 전체 성능 요약 (AUC, Accuracy, Precision, Recall, F1-score)

모델	Macro Precision	Macro Recall	Macro F1	Weighted Precision	Weighted Recall	Weighted F1
RandomForest + SMOTE	0.62	0.60	0.60	0.63	0.64	0.63

XGBoost + SMOTE	0.61	0.59	0.59	0.62	0.64	0.62
-----------------	------	------	------	------	------	------


[표 9] 모델별 Macro / Weighted Score 비교



[그래프 17] 최종 모델 ROC Curve와 AUC 지표

5.3. 피처 중요도 분석

최종 모델인 RandomForest(SMOTE 기법 사용)를 활용하여 피처 중요도를 분석한 결과, 주요 변수는 1위 ‘day1_stay_time’(첫째 날 재실시간, 초단위), 2위 ‘drop_12’(Day1 → Day2 감소율), 3위 ‘initial_cos_hour’(최초 방문 시각 cos 변환), 4위 ‘initial_cos_month’(최초 방문 월 cos 변환), 5위 ‘initial_sin_week’(요일 sin 변환), 6위 ‘day2_stay_time’(둘째 날 재실시간, 초단위), 7위 ‘initial_sin_hour’(최초 방문 시각 sin 변환), 8위 ‘initial_sin_month’(최초 방문 월 sin 변환), 9위 ‘trial_sin_week’(요일 sin 변환), 10위 ‘day1_site_id’(첫째 날 방문한 지점) 등의 순으로 나타났습니다. 이러한 피처 중요도 분석을 통해, 고객들의 ‘초기 경험’과 ‘지속 참여’가 결제 전환에 영향을 미침을 알 수 있습니다.



[그래프 18] RandomForest + SMOTE 모델 피처 중요도


6. 클러스터링 결과 및 해석 | Clustering Results & Interpretation

6.1. 사용한 클러스터링 모델 및 선정 이유

고객 행동 기반 세그먼트를 정의하기 위해 대규모 데이터에서도 확장성이 높고, 각 군집 간 행동 차이를 직관적으로 비교할 수 있는 K-means 군집분석 기법을 활용하였습니다. 최적의 군집 수(k)를 선택하기 위해 Elbow Method와 Silhouette Score 두 가지 평가 지표를 함께 사용하였습니다.

먼저, Elbow Method에서는 k=3~4 구간에서 관성(Inertia)의 감소가 완만해지는 지점이 나타났으며, 단순 계산으로는 k=4가 무난한 분기점으로 해석할 수 있었습니다. 다음으로, 군집의 품질을 평가하는 Silhouette Score 분석 결과에서는 k=3이 가장 높은 점수(0.3787)를 기록하여 군집 간 분리가 가장 명확하게 나타났습니다. 반면, k=4에서는 실루엣 계수가 0.3008로 급격히 하락하여 군집 간 경계가 흐려지는 경향이 확인되었습니다.

결과적으로, Silhouette Score만 고려하면 k=3이 최적이었으나, 실제 고객 행동 패턴이 세분화되어 해석 가능하도록 나타나는 점, Cluster 2처럼 특수 VIP 군집이 존재하는 점 등을 고려하여 비즈니스적 해석 가능성을 최우선으로 삼아 k=4를 최종 군집 수로 선정하였습니다. 따라서 본 분석에서는 Elbow Method의 안정성 + Silhouette Score의 품질 평가 + 비즈니스 해석력을 종합하여 k=4 모델을 최종적으로 채택하였습니다.



[그래프 19] Elbow Method를 통한 최적의 k값 탐색 (좌) / [그래프 20] 실루엣 계수 확인을 통한 최적의 k값 탐색 (우)

6.2. 결과 및 각 군집별 프로파일링

K-means 군집 분석의 결과, 총 4개의 주요 군집이 도출되었으며, 각 군집의 결제율은 34%~50% 수준으로 의미 있는 차이를 보여 전략 타겟팅의 근거를 마련할 수 있었습니다. 각 세부 세그먼트의 구체적인 특징은 다음과 같습니다.

첫째, Cluster 0 그룹은 ‘초기 관심 후 이탈형’(2,374명, 전체의 약 30%)으로, Day1 체류시간은 평균 수준이나 Day2·Day3 방문이 거의 없었습니다. 또한, Day1 이후 체험을 지속하지 않는 빠른 이탈 그룹으로, 전환율 34%로 가장 낮게 나타났습니다. 이를 통해, Cluster 0 그룹은 Day1 체험 후 리마인드 및 방문 유도 전략이 필요한 고객군으로 예상해 볼 수 있습니다.

둘째, Cluster 1 그룹은 ‘고관여 완주형’(전체의 약 23%)으로, Day1~Day3까지 체류시간 모두 길다는 특징이 있습니다. 등록 직후 바로 방문을 시도하고 재방문이 지속되는 패턴을 가지며, 전환율은 42.9%로 전체 중 2위로 높게 나타납니다. 즉, Cluster 1 그룹은 서비스 가치를 명확히 인지하고 참여도가 높은 핵심 고객군으로 볼 수 있습니다.

셋째, Cluster 2 그룹은 ‘극소수 VIP형’(전체의 1~2%)으로, Day1~Day3까지의 체류시간이 전반적으로

짧지만 Day3까지 방문을 완료하며, 짧은 시간 안에 체험을 끝내고 판단하는 행동 패턴을 보입니다. 등록 이후 짧은 시간(2.17일) 내에 방문하는 행동 패턴을 보입니다. 결제 전환율은 50%로 전체 그룹 중 1위를 차지하는 그룹입니다.

마지막으로, Cluster 3 그룹은 ‘자연 소극형’ (전체 약 33%)으로, Day1은 평균 수준의 체류 시간을 보이고, Day2부터 체류시간이 증가하는 경향을 보입니다. Day1~Day3로 일수가 지날수록 방문 감소율이 낮아져, 어느 정도 방문이 유지되는 흐름을 보입니다. 결제 전환율은 40.3%로 전체 중 3위를 차지하였습니다. 즉, Cluster 3 그룹은 초반의 관심은 낮지만 천천히 적응하는 고객군으로 볼 수 있습니다.

구분 \ Cluster	Cluster 0	Cluster 1	Cluster 2	Cluster 3
고객 수	2,374	1,329	1,875	2,500
Day1 체류시간	14,323	23,078	10,377	14,395
Day2 체류시간	4,913	29,703	6,745	4,995
Day3 체류시간	120	17,534	1,893	177
Days_to_visit (신청일부터 첫 방문까지 걸린 일수)	1.19	0.73	2.17	1.18
Drop_12 (Day1 → Day2 감소율)	0.38	-3.69	-0.69	0.32
Drop_23 (Day2 → Day3 감소율)	0.30	-1.41	0.49	0.29
Payment_rate (결제 전환율)	34.46%	42.96% (최고)	50.00% (결제율 1위, 극소수군)	40.32%
visit_days (방문 일수)	1.41	2.87	1.75	1.41

[표 10] 각 군집별 핵심 행동 요약

결론적으로, 3일 체험 데이터를 기반으로 K-means 군집분석을 수행한 결과, 고객은 크게 두 가지(이탈형 고객군(Cluster 0), 완주형·고관여 고객군(Cluster 1, 3, VIP Cluster 2))의 주요 행동 유형으로 구분할 수 있었습니다.

고객 구분	세부 내용
이탈형 고객군 (Cluster 0)	Cluster 0 — 초기 관심 후 이탈형 (~2,374명, 전체의 약 30%)
완주형 / 고관여 고객군 (Cluster 1, 3 / VIP Cluster 2)	Cluster 1 — 고관여 완주형 (전체의 약 23%) Cluster 2 — 극소수 VIP형 (전체의 1~2%) Cluster 3 — 자연 소극형 (전체 약 33%)

[표 11] 클러스터링 결과 요약

특히 Cluster 0은 전체의 30%로 규모가 크지만 전환율이 34%로 가장 낮아, 짧은 체류 → 빠른 이탈로 이어지는 전형적인 Early Drop 패턴을 보였습니다. 반면, Cluster 1·3은 Day1~3 이용시간이 길고 drop 값이 낮아 서비스에 지속적으로 참여하며 비교적 전환율이 높게 나타났습니다. Cluster 2는 극소수지만 결제율이 50%로 가장 높았으며, 체험 기간을 빠르게 끝내고 결정을 내리는 의사결정 고객군임을 확인할 수 있었습니다. 이를 통해 전환 개선 핵심은 이탈형 고객(Cluster 0)을 Day2까지 유도하고, Day1 체류시간 강화, Day2 방문 리마인드, 동기 제공 전략이 효과적일 것으로 예상해 볼 수 있습니다. 또한, 고관여군 그룹은 업셀링·추천 서비스 타겟으로 적합하다고 판단됩니다.

7. 전략 제안 및 기대효과 | Strategic Recommendations & Expected Impact

7.1. 제안 요약 : 마지막까지 완주하게 만들 3단계 마케팅 전략 제안

앞서 분석을 통해 얻어낸 핵심 발견(4장)과 예측 모델(5장), 클러스터링(6장) 내용을 바탕으로, 다음과 같은 4단계의 마케팅 전략을 제안하고자 합니다. 첫째, 초기 이탈형 고객(Cluster 0) 대상으로 첫 날 방문한 경험의 만족도를 강화해 Day2·Day3 방문을 유도하는 ‘첫날 몰입 패키지’를 제안합니다. 둘째, 완주형 고객(Cluster 1·3)을 대상으로 체험 기간 내에서 이미 충성도가 높은 고객을 장기 구독으로 연결할 수 있는 업셀링 유도 전략을 제안합니다. 셋째, 극소수지만 결제율이 가장 높은 빠른 판단형(VIP) 고객(Cluster 2)을 대상으로 전환 속도를 극대화할 수 있는 ‘초고속 전환 패스’를 제안합니다.

7.2. 제안1 : 초기 이탈형 고객(Cluster 0) 대상 ‘첫날 몰입 패키지’

Day1 체류시간은 평균 수준이나 Day2·Day3 방문이 거의 없었던 Cluster 0 그룹의 전환율을 높이기 위해, 첫날 체험의 만족도를 상승시킬 수 있는 UX환경 마련, 체험 후 리마인드 및 Day2·Day3 방문을 유도하는 ‘첫날 몰입 패키지’를 제안합니다.

먼저, 고객의 첫날 체험 만족도가 높아질 수 있도록 방문 전 사용 안내 내용을 스낵 콘텐츠 형식으로 앱에서 확인할 수 있도록 Push 알림 메시지 전송하거나, 아직 공간에 익숙하지 않을 방문자를 위한 실시간 챗봇·비대면 고객 센터 등을 통해 문의사항이나 불편 사항에 빠르게 대응함으로써 고객 경험을 긍정적으로 만들 수 있습니다.

더불어, 행동 기반 실시간 ‘1-Day Nudge’ 메시지를 발송하여 고객에게 리마인드 할 수 있습니다. 예컨대, Day1에 이용한 고객이 퇴실한 직후 ‘내일도 보면 좋겠어요’, ‘내일은 위스키&간식 데이에요!’, ‘2일차 출석 완료하면 프린터 이용 1회 무료’와 같은 마케팅 메시지를 발송하여 고객의 흥미를 불러일으키고, Day2·Day3 방문을 유도할 수 있는 마케팅 캠페인을 진행하는 것입니다.

이를 통해 첫날 체험 만족도 상승 → 전체 체험일수 증가 → 결제 전환율 향상의 기반 마련할 수 있습니다. 또한, 피쳐 중요도 2위였던 ‘drop_12’를 감소시켜 Early Drop 패턴을 약화시키고 이탈 감소로 이어져 전체 Funnel 안정화 효과를 기대해 볼 수 있습니다.

7.3. 제안2 : 완주형 고객(Cluster 1·3) 대상 ‘업셀링 유도’

체험 기간 내에서 이미 충성도가 높은 고객인 Cluster 1·3 그룹의 기존 체류 패턴을 유지 및 강화하여 장기 구독으로 연결할 수 있는 ‘업셀링 유도’ 전략을 제안합니다.

예측 모델의 피쳐 중요도 중 시간과 요일 변수의 중요도(3위 : ‘initial_cos_hour’ (최초 방문 시각 cos 변환), 9위 : ‘trial_sin_week’ (요일 sin 변환))로 미루어 볼 때 요일·시간대별 프로모션이 효과적일 것으로 사료되는 바, 방문 요일·시간대별 개인화 마케팅 캠페인을 진행하는 것입니다. 예컨대, 일과를 마치고 저녁에 방문한 고객을 대상으로 ‘야간 패스’, ‘심야 패스’ 등의 추가 프로모션을 안내하는 Push 알림을 발송하여 고객의 니즈가 있는 시간대에 더 많은 혜택으로 이용할 수 있도록 하여 결제 전환을 유도해 볼 수 있습니다.

또한, 방문 2일차의 체류 시간이 결제 전환에 중요한 영향을 미칠 수 있기 때문에 (6위 : day2_stay_time) ‘현재 oo지점의 워크 모듈에 자리가 많아요!’, ‘oo시 이후로는 붐비지 않아서 쾌적해요!’ 등의 마케팅 메시지를 발송하여 첫 날에 이어 2일차, 3일차까지 지속적으로 긍정적인 경험을 심어주고, 점진적으로 공간에 몰입하며 체류하는 패턴을 강화할 수 있습니다.

이를 통해, ‘이용할수록 좋아지는 콘셉트’가 있는 공유오피스로서 자리잡고, 방문 2일~3일차까지의 체류시간이 증가하면서 고객의 결제 전환부터 장기 구독까지 이어질 수 있을 것입니다. 긍정적인 경험이 지속된다면 ‘무제한

회원권', '지정석' 추가 결제 등까지 이어질 수 있기 때문에 수익 창출에 효과적일 것으로 판단됩니다.

7.4. 제안3 : 빠른 판단형 고객(VIP)(Cluster 2) 대상 '초고속 전환 패스'

소수 집단이고 체류 시간은 짧지만, 1일~3일까지 전부 방문하면서도 결제율이 가장 높은 Cluster 2을 위한 '초고속 전환 패스'를 제안합니다.

이 그룹은 방문 목적이 명확하고 공간 사용 의지가 높기 때문에, 예컨대, 3일차 도달했을 때 빠르게 전환하도록 '체험이 끝나셨나요? 바로 결제 가능한 '간편결제'를 이용해보세요!' 등의 알림을 발송하고, 결제 화면에서 첫 번째로 제안하여 단순화된 결제 흐름을 제공할 수 있습니다.

이처럼 빠른 결정을 하는 고객군을 지속적으로 모니터링하고 마케팅 전략을 실행함으로써, 'VIP 고객군'의 결제 전환율을 극대화할 수 있을 것입니다. 또한, 고객이 빠른 결정을 할 수 있도록 도와 불필요한 체험 기간이 감소되어 운영 효율도 높아질 수 있을 것으로 판단됩니다.

8. 측정 계획 | Measurement Plan

8.1. 초기 이탈형 고객(Cluster 0) 대상 ‘첫날 몰입 패키지’의 효과 측정계획

‘첫날 몰입 패키지’는 행동 지표(Behavioral)와 전환 지표(Conversion), 운영·품질 지표(Qual / Ops)로 나누어 하기와 같이 효과를 측정할 계획입니다.

(1) 행동 지표 (Behavioral)

지표	측정 방법	기대 패턴
drop_12 감소율	(Day1 - Day2 stay) / (Day1 + 1) 전후 비교	drop_12 감소 → Day2 체류 증가
visit_days 증가	1→2→3일 방문 비중 변화	1일 체험 비중 ↓, 2·3일 체험 비중 ↑
nudge 메시지 클릭률/재방문율	메시지 클릭 → 다음날 방문 여부 추적	클릭률 높을수록 유의한 nudge 효과

(2) 전환 지표 (Conversion)

지표	측정 방법	기대 패턴
Cluster 0 결제 전환율 변화	A/B test 또는 기간 전후 비교	전환율 상승
체험 → 결제까지의 리드타임 단축	days_to_visit 변화 확인	첫 경험 만족도가 높아 결정을 빠르게 내리고 전환

(3) 운영·품질 지표 (Qual / Ops)

지표	측정 방법	기대 패턴
고객문의 처리 SLA(응답시간)	챗봇/센터 응답시간 모니터링	빠른 대응 → 만족도 개선
CS 관련 불만 건수 감소	태깅 기반 불만 등 다각도의 불만 유형 수집	초기 경험의 마찰 감소

8.2. 완주형 고객(Cluster 1·3) 대상 ‘업셀링 유도’ 전략의 효과 측정계획

‘업셀링 유도’ 전략은 행동 지표(Behavioral)와 전환 지표(Conversion), 프로모션 효과 지표로 나누어 하기와 같이 효과를 측정할 계획입니다.

(1) 행동 지표 (Behavioral)

지표	측정 방법	기대 패턴
day2_stay_time 증가	프로모션 노출 시점 기준 before/after	체류시간 증가 = 충성도 강해짐
야간·심야 방문 비율 변화	initial_cos_hour 기반 segmentation	시간대 프로모션 효과 검증

trial_sin_week 기반 요일별 재방문율	요일별 visit_days 비교	고객 선호 패턴 강화
-------------------------------	-------------------	-------------

(2) 매출·전환 지표 (Conversion)

지표	측정 방법	기대 패턴
장기 구독 전환율	월 구독/지정석/무제한 패스 가입 전환율 비교	업셀링 효과 입증
ARPU / LTV 변화	클러스터별 구매 흐름 분석	완주형 고객의 단가 상승

(3) 프로모션 효과 지표

지표	측정 방법	기대 패턴
개인화 알림 CTR	시간·요일 기반 캠페인 CTR	CTR 상승 = 타이밍 맞는 마케팅
알림 기반 '세션 시작률'	푸시→방문 연결률	'지금 자리 여유 있어요!' 효과 감지

8.3. 빠른 판단형 고객(VIP)(Cluster 2) 대상 ‘초고속 전환 패스’의 효과 측정계획

‘초고속 전환 패스’는 전환 지표(Conversion), 운영 효율 지표, 경험지표(UX)로 나누어 하기와 같이 효과를 측정할 계획입니다.

(1) 전환 지표 (Conversion)

지표	측정 방법	기대 패턴
3일차 방문 고객의 즉시 결제율	3일차 알림 발송군 vs 미발송군 비교	즉시 결제(간편결제) 증가
체험 종료 당일 결제율	‘초고속 결제 패스’ 클릭 기반	빠른 결정 고객의 전환 최적화

(2) 운영 효율 지표

지표	측정 방법	기대 패턴
평균 체험일수 감소	기존 2.1일 → X.X일 감소	체험 비용/운영 리소스 절감
체험 대비 결제 전환율 (효율지수)	전환율 / 체험일수	‘높은 효율 고객’ 증가

(3) 경험 지표(UX)

지표	측정 방법	기대 패턴
결제 플로우 이탈률(Funnel Drop)	결제 화면 진입 → 완료	첫 화면에 노출되면 drop 감소
간편결제 클릭률	CTA 버튼 클릭률	단순화된 UX의 영향 측정

9. 부록 | Appendix

9.1. 데이터 명세서


제공받은 데이터의 명세서는 다음과 같습니다.

테이블명	테이블 설명	컬럼명	TYPE	설명
site_area.csv	지점별 면적	'site_id'	int64	지점 id
		'area_pyeong'	int64	지점 면적
trial_access_log.csv	3일체험 신청자 출입기록	'id'	int64	index
		'checkin'	int64	입실 : 1, 퇴실 : 2
		'cdate'	object	출입 로그 생성 시각
		'site_id'	int64	지점 id
		'user_uuid'	object	유저id
trial_payment.csv	3일체험 신청자 결제 여부	'is_payment'	int64	결제 시 : 1, 미결제시 : 0
		'user_uuid'	object	유저id
trial_register.csv	3일체험 신청	'trial_date',	object	3일체험 신청시각
		'user_uuid'	object	유저id
trial_visit_info.csv	3일체험 신청자 일자별 방문기록	'site_id'	nt64	지점 id
		'date'	object	이용날짜(KST)
		'stay_time'	object	재실시간
		'stay_time_second'	nt64	재실시간 초단위
		'first_enter_time'	object	해당일자 첫 입실 시각 (KST)
		'last_leave_time'	object	해당일자 마지막 퇴실 시각 (KST)
		'user_uuid'	object	유저id

[부록 표] 데이터 명세서

9.2. 연·월·요일·시간대별 방문 고객 탐색

연·월·요일·시간대별 방문 고객에 대해 탐색한 결과는 다음과 같습니다.



[부록 그래프] 월별 방문 고객 추이(Monthly Unique Users) (좌) / [부록 그래프] 요일별 방문량(Receptions by Day of Week) (우)

9.3. 한계점 및 향후 과제

본 분석에서는 데이터 기반의 몇 가지 한계점이 있었습니다.

(1) 데이터 품질 및 수집 구조의 한계

- ① 입·퇴실 로그 누락 발생 가능성 : trial_visit_info에서 first_enter_time과 last_leave_time 결측이 다수 존재하여, 분석 과정에서 ‘순수 재실시간(stay_time)’만 사용해야 했습니다. 이로 인해 세부 체류 패턴(자리 이동, 휴식 시간 등)을 파악하는 데 제약이 있었고, 출입 태깅의 누락 가능성이 있어 고객의 방문 횟수나 시간대 정보가 실제보다 적게 기록되었을 수 있었습니다.
- ② 3일 체험 설계 특성으로 인한 행동 다양성 제약 : 무료 체험이 최대 3일이라는 고정된 기간을 가지므로, ‘장기 고객의 실제 사용 패턴’과 ‘단기 체험 패턴’이 혼재되어 구분이 어려웠습니다. 예를 들어, Cluster 2의 ‘빠른 판단형’ 고객은 실제 업무 목적이 아닌 ‘체험만 빠르게 확인하는 고객’일 가능성도 존재합니다.
- ③ 결제 여부만을 타깃으로 한 이진 분류의 한계 : ‘is_payment’는 ‘결제 여부(0/1)’만 제공되어, 결제 후 유지 기간이나 환불 여부, 실제 유료 사용 빈도(LTV) 등의 장기 ROI를 반영하지 못했습니다. 이는 모델이 “즉시 전환 가능성”에만 최적화되게 만드는 구조적 한계였다고 볼 수 있습니다.

(2) 모델링 접근 관점의 한계

- ① 예측 성능의 구조적 제약 (Recall 0.41) : RandomForest + SMOTE 모델의 Recall(결제 고객 탐지력)은 약 0.41 수준으로, 불균형 데이터(SMOTE로 완화됨에도 불구하고)의 특성상 결제 고객 패턴 변동성이 커 완전한 학습이 어려운 구조였습니다. 또한, 결제 행동은 체류시간·방문일수 같은 정량 데이터 외에도 업무 목적, 경제 상황, 개인 일정 등 정량화되지 않은 외부 요인의 영향을 크게 받기에 모델의 성능 상한선이 존재하는 상황이었습니다.
- ② 군집분석(K=4)의 해석 가능성 중심 결정 : k=4는 비즈니스 해석 가능성을 고려한 최적값이지만, Cluster 2(VIP형)가 매우 소수(1~2%)인 점, Cluster 3의 패턴이 비교적 애매함 등의 문제가 있어 군집 간 분리가 완벽하게 구조화되었다고 보기는 어렵습니다. 이는 추후 Gaussian Mixture Model, HDBSCAN 등 밀도 기반 모델을 활용하면 더 자연스러운 고객 세분화가 가능할 수 있습니다.

(3) 분석 범위 측면의 한계

- ① 지점(site) 단위 특성 반영의 부족 : 현재 분석에서는 site_id를 단일 변수로 사용했지만, 지점별 혼잡도, 좌석 구성, 지역 상권 특성 등이 결제 전환에 영향을 줄 가능성이 있습니다. 현 구조에서는 지점 간 차이를 반영한 교차분석 또는 정규화가 부족했습니다.
- ② 시간대별 사용 맥락(Context) 분석 미흡 : Heatmap 분석으로 ‘퇴근 시간대(18~21시)’가 중요한

패턴임은 확인했지만, 회의실 예약 여부, 특정 요일 이벤트, 사용자 개인 루틴 등 과 같은 행동 맥락은 반영하지 못했습니다.

이러한 한계점을 극복하고 한층 심도있는 분석을 위해, 하기와 같은 내용을 향후 과제로 수행하고자 합니다.

- (1) ‘일부 방문자 vs 3일 완주자’의 심층 비교 분석 : 리드타임은 0·1일이지만 1일만 방문한 고객 vs 3일 완주 고객의 두 집단을 비교하여 “왜 어떤 고객은 완주하지 않는가?”를 밝히는 추가 분석을 진행합니다. 이를 통해 Early Drop의 원인을 규명하고 Cluster 0 개선 전략의 정확도 향상이 가능할 것입니다.
- (2) 장기 고객(LTV) 기반 예측 모델로 확장 : 현재는 *결제 여부*만 예측했지만, 향후에는 실제 유료 가입 유지 기간(Subscription duration), 결제 후 재방문 빈도, 월평균 이용시간, 지점별 이동 패턴(멀티사이트 사용자 등) 등의 목표 변수를 고려할 수 있습니다. 이는 고가치 고객 예측 모델(LTV Prediction) 개발로 확장될 수 있습니다.
- (3) 세그먼트별 행동 변화 추적(Sequential Pattern Analysis) : 방문 순서나 시간 흐름에 따라 고객 패턴이 달라질 수 있으므로 Markov Chain, Sequence mining과 같은 기법을 활용하면 ‘어떤 행동 시퀀스가 결제로 이어지는가?’를 더 정교하게 분석할 수 있으리 것입니다.
- (4) A/B 테스트 기반의 실제 캠페인 검증 필요 : 전략 제안(7장)은 군집 프로파일을 기반으로 했지만, 실제 효과를 검증하기 위해서는 다음과 같은 실험 설계가 필요합니다. 따라서, Day1 퇴실 후 Nudging 메시지 발송 그룹 vs 비발송 그룹, Day2 리마인드 푸시 → 재방문을 변화 측정, Up-selling 패키지 추천 → 결제 단가 변화 측정의 과정을 거칠 수 있습니다. 이를 통해 모델 기반 전략을 실제 비즈니스 임팩트로 연결할 수 있을 것입니다.
- (5) 외부 요인 결합 분석 (업무카테고리, 직업군, 학습 목적 등) : 체험 고객은 매우 다양한 목적 (업무·공부·사이드프로젝트 등)을 가지고 있어 유형화가 어려운 특성이 있습니다. 향후 간단한 설문 연동 (가입 시 목적 선택), 이용 로그(회의실 예약, 프린터 사용 등) 데이터를 결합하면 정교한 고객 프로파일링이 가능해질 것입니다.